Projeto de Detecção Facial

(Ativ. 4 - Etapa 02)

Squad 01:

Camila Dias, Erivelton Lima, Herik Douglas, Jaqueline de Lima, Paulo Nicacio, Raquel Azevedo, Ulisses Bonfim, Vitor Pires

Sumário

- Introdução
- Problemas do Dataset
- Métodos da Literatura
- Vantagens x Desvantagens
- Métodos Próprios
- Conclusão
- Referências

Introdução

Dataset Face-Detection

- Conjunto de imagens para detecção de faces em imagens, com anotações de bounding boxes em formato padrão e em formato YOLO.

- Há 16.733 imagens, sendo 13386 de treino e 3347 de validação.

- Todas as imagens possuem labels, sem erros aparentes, imagens corrompidas ou duplicatas.

- Inconsistência no tamanho das imagens.

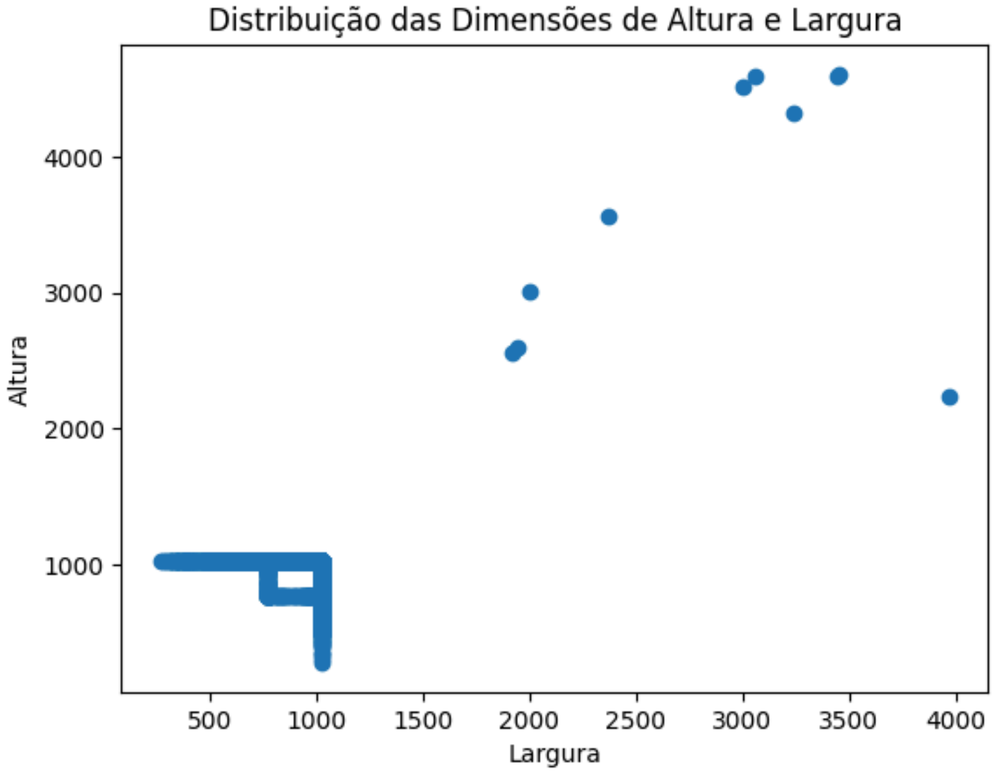

Problemas do Dataset

- **Inconsistência no tamanho das imagens:** variações que exigem redimensionamento, podendo causar distorções faciais, perda de detalhes em imagens pequenas e artefatos de interpolação.

- **Desbalanceamento de amostras e diversidade:** viés de representação (idade, gênero, etnia) e pouca variedade de ambientes reais, prejudicando a generalização.

- **Problemas de qualidade das imagens:** oclusões, iluminação inadequada, baixa resolução e desfoque.

Problemas do Dataset

- **Alta variabilidade de pose e ângulo:** diferenças entre faces frontais e de perfil, além de variações de expressão.

- **Erros de anotação (Ground Truth):** bounding boxes imprecisos, faces parcialmente marcadas ou não rotuladas.

- **Risco de overfitting:** modelo aprende padrões específicos do dataset e perde desempenho em novos dados.

- **Escala e Proporção:** O modelo pode ter dificuldade em detectar rostos que ocupam apenas uma pequena fração da imagem (pessoas distantes), focando apenas nos rostos que estão em primeiro plano.

Métodos da literatura

Haar Cascade

Um dos primeiros detectores de face em tempo real proposto por Paul Viola e Michael Jones em 2001. Utiliza características do tipo Haar e um classificador em cascata para identificar padrões em imagens.

HOG + SVM

O modelo HOG + SVM combina o descritor de características Histogram of Oriented Gradients (HOG), que extrai padrões de bordas e gradientes de uma imagem, com um classificador Support Vector Machine (SVM) para realizar tarefas de detecção ou classificação de objetos.

YOLO v11

Modelo de detecção em tempo real que usa uma única rede neural otimizada para extrair características e prever caixas delimitadoras (bounding boxes) e classes de objetos.

Vantagens x Desvantagens

	Haar Cascade	HOG + SVM	YOLOv11
Vantagens	Rapidez	Boa precisão	Alta precisão
	Baixo custo computacional	Boa generalização	Detecta múltiplas faces
Desvantagens	Baixa precisão	Processamento mais lento	Alto custo computacional
	Sensível a variações de iluminação, rotação e oclusão	Sensível à rotação	Treinamento complexo

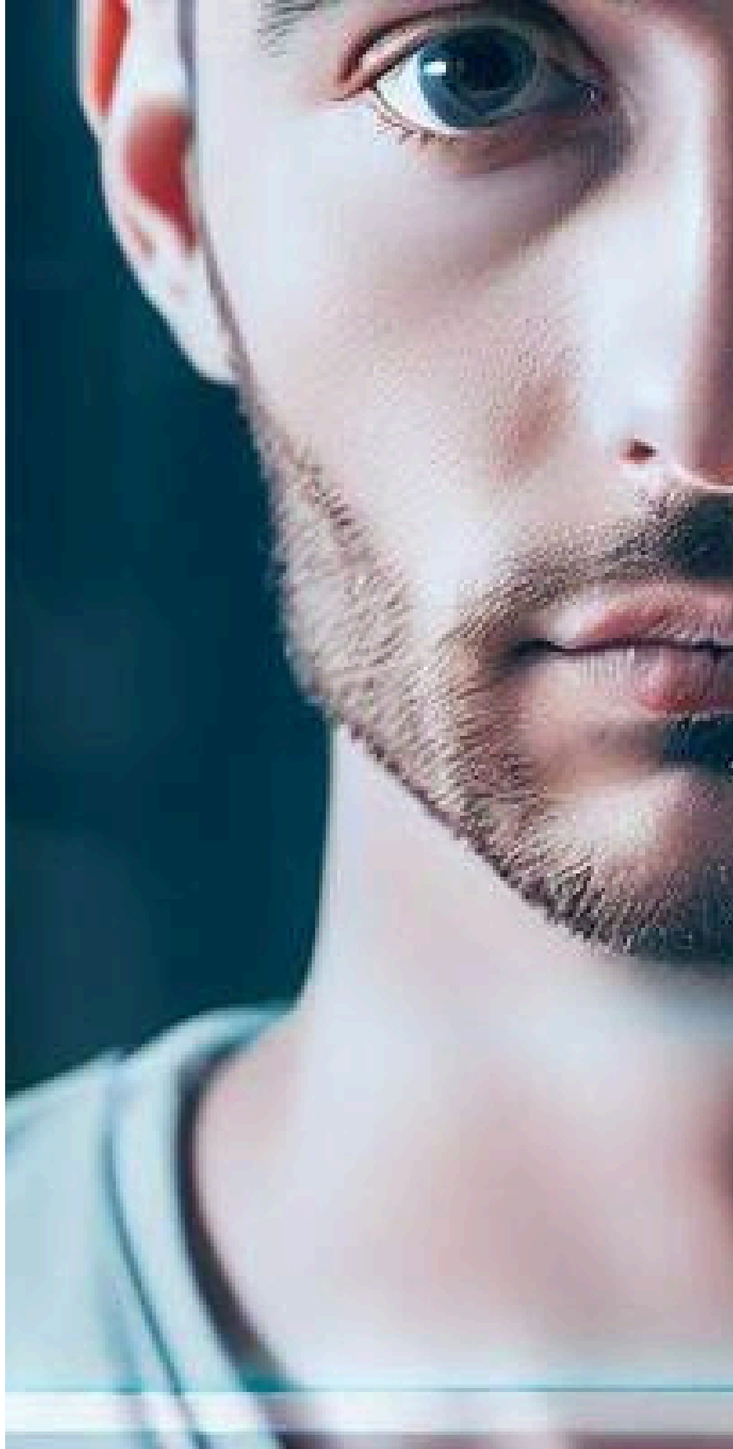

Métodos Próprios

Ideia 01 - Padronização do Tamanho das Imagens

- Redimensionar as imagens do dataset para um tamanho fixo antes do treinamento.
- Reduzir a variabilidade espacial e o custo computacional dos modelos.

Ideia 02 - Data Augmentation

- Aplicar rotações, variações de brilho/contraste, ruído e recortes aleatórios.
- Melhorar a generalização do modelo e reduzir overfitting.

Ideia 03 - Otimização de Hiperparâmetros

- Ajustar hiperparâmetros dos modelos (ex.: learning rate, batch size e resolução).
- Buscar melhor desempenho com maior eficiência computacional.

Conclusão

Qualidade dos Dados vs. Complexidade do Modelo:

- O sucesso da detecção depende mais de um pipeline de dados tratado do que apenas da complexidade do algoritmo.

Eficiência na Escolha do Algoritmo:

- A literatura nos guia para a solução com melhor custo-benefício, evitando complexidade desnecessária para métricas satisfatórias.

Base para Experimentação:

- A análise das problemáticas do dataset (vieses e inconsistências) estabelece o fundamento para os próximos testes práticos.

Referências Bibliográficas

DALAL, Navneet; TRIGGS, Bill. **Histograms of Oriented Gradients for Human Detection**. In: IEEE COMPUTER SOCIETY CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2005. Proceedings [...]. San Diego: IEEE, 2005. p. 886–893. Disponível em: <https://ieeexplore.ieee.org/abstract/document/1467360>. Acesso em 27 Fev. 2026.

MITTAL, Aditya. **Haar Cascades, Explained**. Analytics Vidhya; 20 dez. 2020. Disponível em: <https://medium.com/analytics-vidhya/haar-cascades-explained-38210e57970d>. Acesso em 26 Fev. 2026.

OPENCV. **OpenCV documentation**. Disponível em: https://opencv.org/. Acesso em: 27 fev. 2026.

REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. **You Only Look Once**: Unified, Real-Time Object Detection. arXiv preprint arXiv:1506.02640, 2015. Disponível em: https://arxiv.org/abs/1506.02640. Acesso em: 27 fev. 2026.

SINGH, Bharat; NAJIBI, Mahyar; DAVIS, Larry S. SNIPER: **Efficient Multi-Scale Training**. arXiv preprint arXiv:1805.09300, 2018. Disponível em: https://arxiv.org/abs/1805.09300. Acesso em: 27 fev. 2026.

Referências Bibliográficas

SUN, Chen; SHRIVASTAVA, Abhinav; SINGH, Saurabh; GUPTA, Abhinav. **Revisiting the Unreasonable Effectiveness of Data in the Deep Learning Era**. arXiv preprint arXiv:1707.02968, 2017. Disponível em: https://arxiv.org/abs/1707.02968. Acesso em: 26 fev. 2026.

TAN, Mingxing; LE, Quoc V. **EfficientNet**: Rethinking Model Scaling for Convolutional Neural Networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019. Proceedings [...]. Long Beach: PMLR, 2019. p. 6105–6114. Disponível em: https://arxiv.org/abs/1905.11946. Acesso em: 27 fev. 2026.

VIOLA, Paul; JONES, Michael J.. **Rapid Object Detection Using a Boosted Cascade of Simple Features**. In: IEEE COMPUTER SOCIETY CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2001. Proceedings [...]. Kauai: IEEE, 2001. p. 511–518. Disponível em: <https://ieeexplore.ieee.org/document/990517>. Acesso em: 26 fev. 2026.

Atlântico Avanti

Obrigado!